

文献調査まとめ

時系列因果探索の応用

時系列因果探索は、異常検知や根本原因分析（root cause analysis,RCA）に広く利用されている技術である。根本原因分析とは、複雑なシステムにおいて複数の異常や障害が同時多発的に観測される際、それらの背後にある「最初に発生した原因」を特定するための分析手法である。現実のシステムでは障害が連鎖的に波及することが多く、観測されるのは結果としての下流異常であり、真の根本原因は直接観測できないことが多い。そのため、因果探索によってシステム内部の因果構造（因果グラフ）を事前に構築することが、効率的かつ高精度な障害原因特定に非常に重要となる。

例 1

例 1 として、インターネット業界のマイクロサービスシステムを挙げる。典型的なインターネットアプリケーションは多数のマイクロサービスで構成される。例えば Sock-shop というオンラインアプリケーションは、異なる技術スタックで実装された 13個のマイクロサービスから構成され、各サービスは独立したコンテナや仮想マシン上で稼働し、HTTP API を通じて通信を行う。各マイクロサービスからは、CPU 使用率、メモリ使用率、レイテンシ、エラー数など、多数の監視指標が継続的に収集される。


データ: 約30変数（13サービス×CPU・Memory、システム負荷、レイテンシなど）

1秒間隔で取得され、約5分間で300行程度の時系列データとなる。

因果探索により、どのサービスで異常が最初に発生したのか、レイテンシ増加の真の原因がどこにあるのか（例：データベースか、キューマスターかなど）を推定でき、AIOps や SRE における root cause 特定を大幅に支援できる。

結果：

		CPU hog				Memory leak			
		Ψ-PC	AMAP	ε-Diag.	RCD	Ψ-PC	AMAP	ε-Diag.	RCD
Top-1	Carts	0.6	0.05	0.2	0.69	0.0	0.14	0.4	0.6
	Catalogue	0.0	0.22	0.2	0.17	0.0	0.0	0.2	0.11
	Orders	0.0	0.01	0.2	0.29	0.0	0.26	0.2	0.45
	Payment	0.0	0.07	0.6	0.17	0.0	0.01	0.4	0.17
	User	0.0	0.29	0.2	0.46	0.2	0.08	0.2	0.71
Top-3	Carts	0.6	0.23	0.4	0.86	0.0	0.2	0.4	0.88
	Catalogue	0.0	0.22	0.2	0.22	0.0	0.0	0.2	0.33
	Orders	0.0	0.36	0.2	0.66	0.0	0.37	0.2	0.56
	Payment	0.0	0.07	0.6	0.4	0.0	0.05	0.8	0.34
	User	0.0	0.53	0.2	0.66	0.2	0.27	0.2	0.84
Top-5	Carts	0.6	0.24	0.4	0.86	0.0	0.25	0.4	0.88
	Catalogue	0.0	0.23	0.2	0.22	0.0	0.0	0.2	0.33
	Orders	0.0	0.51	0.2	0.66	0.0	0.49	0.2	0.56
	Payment	0.0	0.07	0.6	0.40	0.0	0.11	0.8	0.34
	User	0.0	0.55	0.2	0.66	0.2	0.3	0.2	0.84



例 2

例2として、製造業におけるアラームフラッド（alarm flood）を挙げる。高度に自動化された産業システムでは、センサー数の増加や相互接続の複雑化により、短時間で大量のアラームが同時に発生することがある。オペレーターの処理能力を超えるアラームが一気に押し寄せると、重要な警報が埋もれ、重大事故につながる危険性が高まる。因果探索を用いることで、アラーム間のトリガー関係を明確化し、アラーム群の中から「根本的に最初に発生したアラーム（root cause alarm）」を特定することが可能になり、オペレーターの負担軽減と迅速な対応に寄与する。

ビジネス応用

富士通は、マイクロサービス提案および監視、産業システムのアラーム管理、設備保全など多くの領域において関連ビジネスを展開している。しかし現状、多くのルートコズ分析は依然として専門家の経験や手作業に依存している。因果探索を活用することで、時系列データを容易に取得できるシステムにおいて、データドリブンの RCA を自動化できる可能性が高い。また、システム構成資料、アラームマニュアル、ログ情報などを RAG + LLM と組み合わせることで、因果推論の精度向上や説明性の強化も期待できる。

一般的なアプローチとしては、いくつかの代表的手法がある。

Granger 因果は「過去の X が Y の予測精度を改善するならば、X は Y に Granger 因果を持つ」と定義するが、あくまで予測因果であり、厳密な因果構造を表すものではない。また同時刻の因果は判断できないため、サンプリング間隔が十分に細かく、因果が時間遅れとして現れる場合に適している。

PC / PCMCI / PCTMI は、条件付き独立性検定（MCI）に基づく制約ベースの時系列因果探索手法であり、高次元データにも対応できるが、独立性検定の安定性を確保するために十分なデータ量が必要となる。

LiNGAM / VAR-LiNGAM は線形構造と非ガウスノイズを前提とする手法で、統計的独立性から因果方向を同定する。即時因果の推定が可能である一方、データ分布に対する仮定が強く、特にノイズがガウスの場合には性能が大きく低下するため、適用前にノイズ特性の分析が必要である。

富士通のビジネス応用としては、因果探索を既存の AIOps、アラーム管理、設備監視ソリューションに統合し、障害伝播経路の推定や root cause の自動特定を実現することが考えられる。さらに、LLM + RAG を活用してシステム設計資料やログ、マニュアルの知識を因果推論に統合することで、専門家レベルの説明性を備えた root cause レポートの自動生成も可能となる。最終的には、「データ」と「知識」の双方を統合したハイブリッド型因果推論プラットフォームを構築し、マイクロサービス、製造業、社会インフラなど多様な領域において、より高度で自動化された運用支援を提供できると期待される。